

NO. 28

DISRUPTIVE PERSPEKTIVER

REISEBREV FRA SILICON VALLEY

AUDUN WICKSTRAND IVERSEN
Porteføljeforvalter

EMILIE KRUTNES ENGEN
Porteføljeforvalter

LEO RUNDGREN OLSEN
Junior Porteføljeforvalter

Hensikten med Disruptive Perspektiver:

Når vi analyserer ulike temaer bruker vi mye tid og mange verktøy (kvartalsrapporter, analyser, dialog med selskapene, bedriftsbesøk, excel, kalkulator og ordmodeller). Ofte lager vi små notater, og noen ganger store notater som vi tenker på som perspektiver. Vi er gamle nok til å vite at det sjeldent finnes sannheter, ofte bare ulike perspektiver.

Disruptive Perspektiver har kun én hensikt: Å dele våre perspektiver på temaer som former vår fremtid. Dette er ikke akademiske notater, innlegg til et leksikon eller anbefalinger om å gjøre noe, kjøpe eller selge noe. Kun god gammeldags informasjonsdeling for å synliggjøre hvordan vi ser på ulike temaer på publiseringstidspunktet. Perspektiver blir ikke mindre, kanskje heller mer, når man deler det. Med det utgangspunktet; ha en fin reise i våre perspektiver.

Innhold

Disclaimer 1

1.0 De store linjene 4

2.0 Selskapene vi møtte 14

3.0 Noen begreper som gjør at du og jeg skjønner litt mer av hva som skjer 21

3.1 Heterogene datasentre 21

3.2 Scale up, scale out & across 25

3.3 Lys, speil & optikk 29

4.0 Avslutning 33

Disclaimer

Innholdet i denne artikkelen er ikke ment som investeringsråd eller anbefalinger. Har du noen spørsmål om fondene det refereres til, bør du kontakte en finansrådgiver som kjenner deg og din situasjon. Husk også at historisk avkastning i fond aldri er noen garanti for fremtidig avkastning. Fremtidig avkastning vil blant annet avhenge av markedsutvikling, forvalterens dyktighet, fondets risiko, samt kostnader ved kjøp, forvaltning og innløsning. Avkastningen kan også bli negativ som følge av kurstap.

Vi har nylig vært i Silicon Valley og møtt 20 selskaper. Dette reisebrevet er ikke et referat fra flyplasser og møterom. Det er et forsøk på å gi dere det samme som vi selv kom hjem med, nemlig et skarpere bilde av hvilke krefter som nå former teknologi, kapital og industri, og ikke minst hva det betyr for hvordan vi forstår risiko og posisjonering i porteføljen.



Silicon Valley er fortsatt det stedet der neste plattform bygges først, og der antakelsene om fremtiden testes hardest. Etter 20 samtaler på kort tid blir enkeltpitchene mindre interessante enn mønsteret mellom dem. Hva alle tar for gitt. Hva som plutselig er blitt knapphetsfaktor. Hvor verdien antas å havne når modellene blir billigere, energien dyrere og intelligensen flytter fra skjerm til fysisk arbeid.

Derfor er brevet bygget i to lag. Først de store linjene, det vil si de underliggende faktorene vi mener er grunnlaget for både forståelse og investeringer. Deretter selskapene. Noen møter bekreftet det vi allerede trodde. Andre tvang oss til å justere kartet. Begge deler er verdifulle. Vi legger også med en diskusjon rundt noen «nye» sentrale begreper som vi under og etter turen opplever som sentrale for å forstå, analysere og investere.

Målet vårt er enkelt. At dere skal kunne lese verden slik vi så den der borte, og forstå hvorfor vi mener visse temaer fortjener mer oppmerksomhet enn enkeltnavn. Investeringer over tid eies sjelden gjennom den beste historien i rommet. De eies gjennom eksponering mot de kreftene som gjør at mange selskaper samtidig kan ha rett.

Her er det vi tok med oss hjem.

Kort oppsummering

1. Etterspørselen etter AI-infrastruktur er fortsatt sterk, og bredere enn for ett år siden. Praktisk talt alle leverandørene vi møtte er begrenset av hva de klarer å produsere, ikke av hva kundene vil kjøpe. Flaskehalsen er fortsatt tilbud, ikke etterspørsel.
2. Tyngdepunktet i AI-investeringene har flyttet seg fra trening av modeller til inferens, altså bruken av dem. Økt bruk endrer hvilken maskinvare som etterspørres, og hvilke selskaper som tjener på det.
3. Selskapenes egne AI-kostnader vokser raskt. Budsjettene økes, delvis på bekostning av at bemanningen vokser saktere eller reduseres.
4. Open-source modeller for kostnadskontroll og datasikkerhet. De mest sofistikerte svarer på økte kostnader ved å ta i bruk open source-modeller på egen infrastruktur.
5. Disaggregert og heterogen compute-infrastruktur er i ferd med å bli implementert. Prosesseringen av en AI-oppgave deles opp og fordeles på skreddersydd infrastruktur. Konseptet er ikke nytt, men på denne turen fikk vi konkrete bevis på at det implementeres.
6. Optikk og nettverk blir en stadig viktigere del av AI-infrastrukturen. Større klynger, høyere hastigheter og inferens med krav til lave forsinkelser, flytter mer av trafikken over på lys, og fra 2028 også innenfor rackene. Nettverket avgjør i økende grad hvor mye man får ut av infrastrukturen.
7. Selvkjørende biler er i ferd med å ta over i San Francisco. Tesla (Robotaxi), Google (Waymo) og Amazon (Zoox) er alle på veiene i San Francisco. Vi fikk testet Tesla til flyplassen (med sikkerhets-sjåfør), og Waymo sine nye, større og kinesiskproduserte biler, mens Zoox fremdeles er begrenset til test-brukere.
8. AI tas i bruk i alle ledd av verdikjeden vi møtte, fra produksjonsutstyr for halvledere til programvare, transport, bank og helse.

1.0 De store linjene

Etter 20 møter i Silicon Valley sitter man sjelden igjen med 20 likeverdige historier. Man sitter igjen med noen få store linjer. Det er poenget med en slik tur. Silicon Valley er ikke først og fremst et sted. Det er et konsentrert laboratorium der fremtidens infrastruktur, forretningsmodeller og kapitalstrukturer testes i sanntid — ofte år før de slår inn i resten av økonomien.

William Gibson har et av våre favoritt-sitater:

«The future is already here - it's just not very evenly distributed»

Silikon dalen er der fremtiden er ujevnt, men tettest, fordelt. Når man møter 20 selskaper på kort tid, ser man ikke bare hva de gjør. Man ser hva de antar om verden, nemlig at etterspørselen etter intelligens er reell, at energien, tomtene og bygningene («land, power and shell») nå er like avgjørende som modellene, at AI flytter ut av skjermen og inn i fysisk arbeid, og at applikasjonslaget (det Jensen Huang kaller toppen av kaken) er der verdien til slutt skal tas ut.

Derfor er de store linjene grunnlaget for både forståelse og investeringer.

Forståelse fordi enkeltteknologi uten kontekst blir mote. Man kan bli fascinert av en agent, en humanoid eller et nytt chipselskap og likevel misse at det egentlige skiftet er en ny industriell stack, som energi, silisium, datasentre, modeller, agenter og deretter fysisk automatisering. Sequoia har formulert det slik at AI ikke er raskere hester. Det er biler. Da endres ikke bare produktet. Da endres hele verdikjeden, tidshorisonten og hva som teller som «edge».

Investeringer fordi avkastning over tid sjelden kommer fra å eie den kuleste storyen. Den kommer fra å eie eksponering mot de underliggende kreftene som gjør at mange selskaper samtidig kan ha rett, og fra å unngå de som bare rir på samme narrativ uten moat, uten inntekter eller uten tilgang til den fysiske kapasiteten verden faktisk mangler. Peter Thiel minner om at «every moment in business happens only once». Den neste store posisjonen

kopierer ikke forrige syklus. Den fanger det som er unikt nå: at intelligens skaleres, at atomer igjen teller, og at kapitalen følger flaskehalsene.

Marc Andreessen sa at software spiser verden. I 2026 er bildet mer presist: digitale agenter spiser verden og verden svarer med strøm, chips, roboter og ny industri. De 20 møtene gir ikke fasiten. De gir kalibrering. De viser hvilke antakelser som er blitt konsensus i Valley, og dermed hvilke spørsmål en investor må stille hardere. Som for eksempel, hvem eier den varige fordelen når modellene blir billigere? Hvem løser den fysiske begrensningen? Hvem bygger noe kundene faktisk betaler for, ikke bare noe som imponerer i demo?

De store linjene er derfor ikke pynt på en reiserapport. De er kartet. Uten dem blir hvert selskap et isolert veddemål. Med dem blir porteføljen et uttrykk for hvordan man tror neste tiår faktisk kommer til å se ut.

Her er linjene vi tok med oss. Og vi deler dem gjerne så lenge du som leser husker at vi forvalter aksjer, og ingen sannheter.

1. Etterspørselen er sterk og bred, og tilbudet er flaskehalsen

Det mest gjennomgående budskapet på turen var at etterspørselen etter AI-infrastruktur fortsatt overgår produksjonskapasiteten. Nvidia var tydelige på at omsetningen i overskuelig fremtid vil være begrenset av tilgang på komponenter og produksjonskapasitet, ikke av etterspørsel, og at eventuell oppside i neste års omsetning må komme fra bedre leveranser fra underleverandørene. Applied Materials har hevet vekstanslaget for utstyrssalget 3 ganger i år, til nær 40%, og beskriver tilgangen på ferdigstilte fabrikker som det som styrer veksten på kort sikt. Arista knytter sin egen vekst direkte til tildeling av komponenter fra Broadcom. Seagate er i praksis utsolgt og lar kundene forplikte seg til volum flere år frem i tid.

Flaskehalsene sitter flere steder i verdikjeden. De viktigste er på komponentsiden; TSMC, som produserer selve brikkene for nesten alle aktørene, samt leverandører av minnebrikker og optiske komponenter. Nvidia hevder at tilgang til energi ikke er en umiddelbar flaskehals, men at det kan føre til forsinkelser av leveranser fra et kvartal til et annet.

En setning fra dette møtet som vi festet oss ved er:

«The demand is not seen in technology before"

Etterspørselen er også bredere enn for ett år siden. Det er ikke lenger bare modell-leverandørene som driver etterspørselen. De store skyleverandørene (hyperscalerne) leverer også bedrifter på tvers av industrier. I følge Nvidia ble salget til stater og nasjonale AI-satsinger tredoblet i fjor og de forventer denne veksten skal fortsette. Som et eksempel nevnte Jensen Huang på Goldman Sachs konferansen (også i San Francisco) at Nvidia skal levere utstyr til 2GW med kapasitet til datasenter-operatører i Australia tilsvarende 80 milliarder USD i 2027. Arista har over hundre kunder som bygger AI-infrastruktur, inkludert universiteter og industriselskaper. NetApp, som selger lagringssystemer til bedrifter, tredoblet antall AI-relaterte prosjekter på ett år.

Et ord som gikk igjen noen ganger var «compute constrained» samt en setning vi tok med oss videre: *«we dont see any slowdown or pause in the horizon»*.

2. Fra trening til inferens

En AI-modell trenes først på enorme datamengder, og tas deretter i bruk. De første årene av AI-bølgen gikk nesten all investering til trening. Nvidia mener vippepunktet ble passert for ett til halvannet år siden, og at majoriteten av det kundene kjøper i dag, går til inferens.

Driverne er såkalte resonneringsmodeller, som bruker mer prosesseringskraft på å arbeide seg gjennom et problem før de svarer, og AI-agenter, som utfører flertrinns-oppgaver på egen hånd, samt kommuniserer med og delegerer oppgaver til andre agenter. Begge deler bruker langt flere tokens per spørring enn en enkel chatbot. Nvidias vurdering er at slike gjennombrudd øker behovet for regnekraft med en faktor på 10 til 100, ikke med noen titalls prosent, og at det derfor ikke lar seg planlegge for innenfor normale investeringshorisonter.

De som har lest våre perspektivnotater kjenner til hvordan vi skiller mellom lineære og eksponentielle modeller. Vi lever i den bratteste delen av S-kurven.

For oss som investorer er poenget at inferens krever en annen sammensetning av maskinvare enn trening. Det trengs mer raskt minne nær brikkene, mer lagringskapasitet for å holde på konteksten i lange oppgaver, flere vanlige prosessorer (CPU-er) til å styre agentene, og mer

pålitelige nettverk. Nvidias neste plattform, Vera Rubin, inneholder derfor egne rack-typer for CPU-er, for inferens med lav ventetid og for lagring, i tillegg til de klassiske GPU-rackene.

3. Tokens er den nye valutaen, og regningen vokser

Arbeidet en AI-modell utfører måles i tokens (små tekstbiter), og bedriftene betaler per token. Det nye på denne turen var hvor stor denne kostnadsposten er i ferd med å bli, og hvor bevisst selskapene er på den.

Enkelte pekte på at tokens allerede utgjør rundt 10% av kostnadsbasen, og at andelen forventes å fortsette og øke fremover. Bemanningsvekst er redusert for å finansiere det, selv om de fortsatt ansetter innen utvalgte områder. Hos Applied Materials er den interne diskusjonen om de bruker nok på tokens gitt avkastningen, samtidig som de innfører forbrukskontroll for å unngå enorme kostnadsoverskridelser. Lam Research fortalte at enkelte ingeniører har ubegrensede budsjetter, og at én dag med agentbaserte arbeidsoppgaver fort koster rundt tusen dollar. I følge OpenAI bruker de mest avanserte bedriftskundene rundt 8 ganger så mange tokens per ansatt som gjennomsnittskunden, og at OpenAI selv ligger mer enn 30 ganger over disse igjen. Det gir en indikasjon på hvor mye vekst som ligger i eksisterende kunder alene.

Mønsteret var det samme hos nesten alle. AI-budsjettene øker, antall ansatte vokser saktere, og produktiviteten per ansatt går opp.

4. De mest sofistikerte bruker open source-modeller på egen infrastruktur

Når token-regningen blir stor nok, begynner bedriftene å se etter alternativer. Det tydeligste eksempelet fikk vi hos Nutanix. Utviklerne deres gikk fra enkle kodeassistenter til stadig kraftigere modeller, og kostnadene mot leverandørene av frontier-modeller (de mest avanserte modellene fra OpenAI, Anthropic og Google) økte kraftig. Løsningen ble å investere rundt 20 millioner dollar i egne Nvidia-servere og kjøre open source-modeller på egen infrastruktur. Målet er å dekke rundt 80% av behovet internt og bare sende de mest krevende oppgavene til frontier-modellene. Investeringen er beregnet å betale seg på 1 år,

mot en avskrivningstid på 5 år. Nutanix fortalte om flere store kunder innen halvledere, farmasi og finans som vurderer det samme.

Applied Materials ønsker å styre hvilke oppgaver som sendes til åpne og lukkede modeller, ut fra kostnad, tid og hensyn til beskyttelse av egen teknologi. Arista pekte på at open source-modeller kombinert med krav til datasikkerhet kan føre til at bedrifter flytter AI-arbeid fra skyen tilbake til egne datasentre.

OpenAI, som lever av å selge tokens, hadde naturlig nok et motargument som er at inferens ikke er gratis for open source-modeller heller, og de mener de er billigere enn de kinesiske åpne modellene når man sammenligner resultatene. Uansett utfall, peker begge retninger mot mer etterspørsel etter servere, lagring og nettverk, enten om det er åpne modeller på egen infrastruktur eller åpne/lukkede modeller levert av skyleverandører.

5. Disaggregert inferens og heterogen compute-infrastruktur tas i bruk

Dette var etter vårt syn den viktigste tekniske utviklingen på turen. Konseptet har vært diskutert en stund, men i år fikk vi konkrete bevis på at det implementeres.

Bakgrunnen er at inferens består av to faser med ulike krav til maskinvaren. I den første fasen (prefill) leser modellen hele spørsmålet og all kontekst, noe som krever mye rå regnekraft. I den andre fasen (decode) genereres svaret token for token, noe som først og fremst krever svært høy minnebåndbredde (skrive til/lese fra minne). Nvidias GPU-er godt egnet til den første fasen. For den andre fasen finnes det spesialiserte brikker med minnet integrert direkte på brikken (SRAM), fra selskaper som d-Matrix, Groq (Nvidia) og Cerebras. Å kjøre de to fasene på hver sin type maskinvare kalles disaggregert inferens, og infrastruktur som kombinerer flere typer brikker kalles heterogen.



Gimlet Labs er en skyleverandør som spesialiserer seg på dette og utvikler programvare som ruter arbeidet mellom brikketypene. Deres data viser 4-10 ganger høyere utnyttelsesgrad på deres infrastruktur, sammenlignet med rene GPU-installasjoner. d-Matrix fortalte at disaggregering har utvidet markedet deres betydelig, fordi kortene deres nå kan brukes på de største modellene i samspill med GPU-er, og at de fleste kundene velger heterogene oppsett fordi det forlenger levetiden på eksisterende GPU-flåter.

Bekreftelsene kom fra flere hold. Nvidias egen Vera Rubin-plattform er i praksis disaggregert, med egne rack for CPU-er, for tokengenerering med lav ventetid og for lagring av kontekst. Nvidias oppkjøp av Groq, som lager nettopp SRAM-baserte inferensbrikker, peker i samme retning. Andre aktører peker også på økt etterspørsel etter systemer med CPU-er beregnet på agent- og inferensarbeid. Selv om Nvidia har sikret seg tilgang på komponenter og virker fortsatt godt posisjonert er vår konklusjon er at verdiskapingen i AI-infrastruktur sprer seg til flere typer brikker og flere leverandører enn for ett år siden.

6. Optikk og nettverk blir stadig viktigere

AI infrastrukturutbygging øker etterspørsel etter nettverksutstyr. Nettverket er i økende grad avgjørende for hvor mye kundene får ut av brikkene, og en større andel av trafikken må flyttes over på lys. Bransjen deler nettverket inn i tre nivåer. Scale-up er forbindelsene mellom

brikkene i samme rack (eller nærliggende racks), scale-out er forbindelsene mellom rackene i samme datasenter, og scale-across er forbindelsene mellom ulike datasentre. Vi ser tre grunner til at optikk og nettverk får en større andel av investeringene på alle tre nivåene.

Scale-out-nettverk eksisterte knapt før 2023 og har alene gitt rundt ti ganger mer optisk trafikk enn telekom-æraen. Neste steg er scale-up. Kobber er fortsatt både billigere og mer strømgjerrig enn optikk over korte avstander, men for hver hastighetsgenerasjon krymper avstanden der kobber er det beste valget. Når ett sammenhengende system skal spenne over flere rack, blir avstand og krav til hastighet for stor, og Lumentum venter at optikk for første gang tas i bruk i stort volum innenfor scale-up-domenet i 2028, som supporteres av planene til Nvidia. Når optikk først må inn, taler strømforbruket for å integrere den tett på brikken (co-packaged optics, CPO) fremfor i pluggbare moduler i frontpanelet, selv om enkelte kunder ønsker å utsette den overgangen så lenge som mulig av hensyn til vedlikehold og innkjøpsfleksibilitet.

Trening er et jevnt, planlagt arbeid. Inferens for agenter er uforutsigbart, med mye trafikk frem og tilbake mellom GPU-er, CPU-er og lagring, og med krav til lav ventetid fordi de raskeste tokenene prises høyest. Det gjør synkronisering og pålitelighet viktigere. Credo viste hvordan én ustabil forbindelse kan stanse en hel klynge med titusenvis av GPU-er, og at nedetid koster millioner per dag. Pålitelighet er dermed blitt et kjøpskriterium på linje med hastighet, også i den delen av nettverket som kobler AI-klyngen til resten av datasenteret.

7. Selvkjørende biler er vanlig i San Francisco

For oss som besøker San Francisco hvert år, er selvkjørende biler et av de tydeligste målene på hvor fort teknologien beveger seg. I år testet vi Teslas robotaxi-tjeneste flere ganger, blant annet til flyplassen. Tesla har fortsatt en sikkerhetssjåfør i setet, men bilen kjørte selv hele veien. Vi observerte betydelig flere Zoox-biler enn i fjor. Zoox er Amazons selvkjørende bil, bygget fra bunnen av uten ratt og pedaler. Waymo, som er markedslederen, har begynt å rulle ut sin nye bilmodell, som er merkbart større (og rimeligere) enn Jaguar-bilene de har brukt til nå, og som produseres av kinesiske Zeekr.



Nvidia beskrev robotaxi som det første kommersielle gjennombruddet for fysisk AI, altså AI som opererer i den fysiske verden, og bekreftet at Waymo, Zoox og Tesla alle utvider til flere amerikanske byer, noe som også driver økt etterspørsel etter AI infrastruktur. De hevder også at enhver bilprodusent som vil matche Tesla må mangedoble sine innkjøp av infrastruktur til trening.

Vi møtte også de to ledende selskapene innen selvkjørende lastebiler. Aurora har kjørt uten sjåfør på motorveiene i Texas siden april 2025 og sikter mot 200 lastebiler på veien ved årsskiftet. Tjenesten prises under det en menneskelig sjåfør koster per mile, og lastebilen kan kjøre rundt dobbelt så langt per år fordi den ikke er underlagt hviletidsregler. Kodiak har 35 lastebiler uten sjåfør i drift på private veier i Texas og sikter mot kjøring uten sjåfør på offentlig motorvei innen utgangen av 2026. California åpnet i år for selvkjørende lastebiler, noe som utvider markedet betydelig.

8. Edge AI: inferens der dataene oppstår

Ikke all inferens skal kjøre i store datasentre. En robot, et overvåkingskamera eller en satellitt kan ikke vente på svar fra skyen. Ventetiden blir for lang, strømforbruket for høyt, og ofte er nettforbindelsen usikker. Inferens som kjøres lokalt i enheten kalles edge AI.

Ambarella, som lager AI-brikker til kameraer, biler og roboter, var tydelige på at datasenterbrikker ikke egner seg i slike produkter; en robot kan ikke ha en vannkjølt GPU. Brikkene deres bruker etter eget utsagn rundt en fjerdedel av strømmen til en GPU med tilsvarende ytelse. De har levert over 50 millioner slike brikker og ser robotikk og droner som den raskest voksende delen av virksomheten. Vi møtte også norske Nordic Semiconductor, som med sin posisjon innen trådløs kommunikasjon jobber med å legge små AI-funksjoner direkte inn i sensorer og wearables. Planet Labs har satt Nvidia-brikker om bord i sine nyeste satellitter, slik at bildene analyseres i bane og bare resultatet sendes ned, for eksempel antall fly på en flyplass, i stedet for hele bildet. Cisco ser for seg AI-agenter som kjører lokalt på kontorpulten. Fellesnevneren er at inferens flytter dit dataene oppstår, og det åpner et marked for andre typer brikker enn de som dominerer i datasentrene.

9. AI adopsjon i hele verdikjeden

Vi spør alltid selskapene hvordan de bruker AI selv. I år var svarene mer konkrete enn noen gang, og de kom fra alle ledd i kjeden:

- Produksjonsutstyr: Lam Research har trent roboter (cobots) på maskinenes egne sensordata og vedlikeholdsmanualer, slik at de kan utføre reparasjoner med en presisjon på 50 mikrometer, konsekvent fra skift til skift. Applied Materials bruker AI til å simulere eksperimenter og oppdage nye materialer, og forventer at produkter kommer raskere til markedet.
- Nettverksutstyr: Cisco leverer allerede produkter som i sin helhet er utviklet av AI, og forventer å ha skrevet om hele sin historiske kodebase med AI-agenter innen neste sommer. Med en av de nyeste modellene gjennomgikk de 11 milliarder linjer kode på sju uker, et arbeid som normalt ville tatt åtte år. Integrasjon med Google tok tre uker, mot over ett år for tilsvarende partnere tidligere.
- Brikkedesign: OpenAI fortalte at deres egen modell fikk fullføre en liste med kjente forbedringer på selskapets første egenutviklede brikke i de siste 30 dagene før designet ble sendt til produksjon.
- Helse: Intuitive Surgical bruker maskinlæring til å varsle kirurgen om vevet i stiftemaskinen er for tykt eller for tynt før den avfyres. Veien videre går via at

roboten tar over enkeltoppgaver, som kamerastyring, til at én kirurg overvåker flere operasjoner samtidig.

- Bank: SoFi har lansert en AI-rådgiver i appen som blant annet finner dupliserte abonnementer og lar kunden avslutte dem med ett klikk og har over en halv million samtaler siden lansering.
- Satellittdata: Planet Labs vant en kontrakt med den amerikanske marinen fordi de fotograferer hele Sør-Kina-havet daglig og lar AI plukke ut det analytikerne bør se på. Ved å integrere AI verktøy på toppen av sine data, kan de også tilby programvare som tidligere krevde skreddersøm per enkeltsegment, som både åpner opp markedet og reduserer utviklingskostnad.
- Programvareutvikling: Nutanix får rundt 25 prosent flere funksjoner per utvikler per år. Arista har bygget en AI-agent som overvåker og feilsøker nettverket

10. Hva vi følger ekstra med på

Vi noterte oss også noen ting som krever oppmerksomhet. Energi nevnes stadig oftere som den neste flaskehalsen; gassturbiner bestilt i dag leveres ikke før i 2030. Kundekonsentrasjonen er høy hos mange leverandører og fortsatt investeringsvekst vil i økende grad kreve gjeldsfinansiering. Hyperscalerne omtaler minne som kostnadsdriver i sine egne regnskaper, noe som driver økt innovasjon knyttet til nye arkitekturer som søker å redusere denne kostnaden (Nvidia tester alternative versjoner av sin neste generasjon, Rubin Ultra, med færre HBM-lag). Geopolitikk, konkurransesituasjon og salg inn/ut av Kina driver fortsatt usikkerhet på tvers av verdikjeden, inkludert kritiske substrater som indium phosphide (forkortet «InP», brukt i optiske komponenter), utstyr til halvlederproduksjon og minne (CXMT og YMTC). Slik vi ser det er det ikke overordnet høye multipler (gitt forventet inntjeningsvekst) på endel av disse selskapene, med andre ord tar markedet (til en viss grad) høyde for at inntjeningsnivåene ikke er bærekraftige. Applied Materials fortalte at spørsmål knyttet varigheten på denne investeringsbølgen, har økt de siste kvartalene. Selv om usikkerheten knyttet til hvor vi er i investeringssyklusen er et gjentakende tema, var inntrykket vi satt igjen med etter turen, at investeringer i AI fortsatt er i strukturell vekst og at vi fremdeles er i en tidlig fase av å ta ut det fulle verdipotensialet denne teknologien muliggjør.

2.0 Selskapene vi møtte

Etter de store linjene kommer bevisene. De tjue selskapene er ikke et representativt tverrsnitt av Silicon Valley, og de er heller ikke en rangering. De er tjue samtaler med folk som bygger i forkant av det markedet allerede priser inn, og noen som bygger der markedet fortsatt nøler.

Noen står midt i modell- og agentlaget. Noen eier flaskehalsene under: energi, chips, nettverk, datasentre. Noen tar intelligensen ut i fysisk arbeid, som robotikk, autonomi, produksjon, forsvar. Noen tar det siste steget og gjør teknologien til noe en kunde faktisk betaler for. Til sammen tegner de et kart over hvor ambisjonen, kapitalen og knappheten møtes akkurat nå.

Vi har ikke forsøkt å gjengi hver pitch. Vi har forsøkt å fange det som faktisk satt igjen etter møtet: hva selskapet tror verden kommer til å mangle, hvorfor de mener de kan eie en del av svaret, og hva det forteller om tidspunktet vi er i. Noen møter bekreftet det vi allerede ante. Andre justerte kartet. Det er de siste som ofte er mest verdifulle.

Hvert selskap står derfor med tre ting i tankene: hvilken linje det tilhører, hva som skiller det fra støyen rundt, og hvilket spørsmål det etterlater til oss som investorer. Ikke «er dette det neste enhjørningselskapet?», men «hvis disse tesene er riktig, hva må da være sant om de neste fem til ti årene, og hvor bør vi da stå?». Vel, her er de 20.

AI-brikker og halvledere

Nvidia (NVDA) – Verdens største leverandør av AI-brikker (GPU-er), og i økende grad komplette datasentersystemer der dataprosessering, nettverk og programvare selges samlet. Fra møtet: Omsetningen begrenses av tilbud, ikke etterspørsel. Flertallet av kjøpene går nå til inferens. Neste plattform, Vera Rubin, inneholder egne rack for CPU-er, tokengenerering med lav ventetid og lagring. Nvidia investerer i optiske leverandører for å sikre kapasitet. De ser robotaxi som det første kommersielle gjennombruddet for fysisk AI, og mener enhver bilprodusent som vil matche Tesla må mangedoble sine innkjøp av regnekraft til trening.

d-Matrix (privat) – Halvlederselskap som designer brikker skreddersydd for inferens. Produktet Corsair er et akseleratorkort der regning og minne ligger tett sammen på brikken

(in-memory compute basert på SRAM), som gjør brikken svært rask i decode-fasen. Fra møtet: Har bestillinger for første halvår 2027 og kunder blant neoclouds; hyperscalere og statlige aktører er i pipeline. Neste generasjon bruker minne stablet direkte oppå brikken.

Gimlet Labs (privat) – San Francisco-selskap som har bygget det de kaller den første multi-silisium inferens-skyen. Programvaren deler én AI-forespørsel opp i faser og sender hver fase til den brikken som passer best, enten det er GPU-er, CPU-er eller spesialiserte inferensbrikker, og selskapet drifter datasentre bygget på dette prinsippet. Uken før vi møtte dem hentet selskapet 300 millioner dollar fra blant andre Andreessen Horowitz til en verdi på tre milliarder, og de oppgir å ha kontrakter verdt flere milliarder dollar og hundrevis av megawatt. Fra møtet: Har signert en stor, flerårig avtale med en ledende AI-lab og samarbeider tett med Nvidia, Cerebras, d-Matrix og Googles TPU-team.

Ambarella (AMBA) – Designer energieffektive AI-brikker til kameraer, biler, droner og roboter, altså brikker som tolker data fra sensorer i den fysiske verden. Har levert over 50 millioner slike brikker. Fra møtet: Gjennomsnittsprisen per brikke har mer enn doblet seg på fem år. Markedsanslaget er hevet til over 20 prosent årlig vekst. Robotikk vokser raskt, og en ny frittstående AI-akselerator er lansert.

Rambus (RMBS) – Lager små, men nødvendige brikker som sitter mellom prosessoren og minnet på serverens minnemoduler. Brikkene utgjør en liten del av modulens kostnad, men modulen fungerer ikke uten dem, og kundene verdsetter leveringssikkerhet fremfor pris. Selger også brikkedesign (IP) og lisensierer patenter. Fra møtet: Brikkesalget økte rundt 40 prosent i fjor. Neste generasjon prosessorer får flere minnekanaler, som gir flere brikker per server. Inferens og agenter øker behovet for CPU kapasitet.

SiTime (SITM) – Lager timing-brikker, referanseklokkene som holder alle komponentene i et datasenter synkronisert, basert på mikromekanikk (MEMS) i stedet for tradisjonell kvarts. Fra møtet: Omsetningen har gått fra litt over 300 millioner dollar i fjor til over en milliard i årlig takt. Innholdet per rack øker med tettere rack, høyere hastigheter og optikk. Kundesegmenter inkluderer alt fra konsumerelektronikk til datasenter-infrastruktur.

QuickLogic (QUIK) – Lite selskap som lager FPGA-er, brikker der logikken kan programmeres om etter produksjon, for luftfart, forsvar og kritisk infrastruktur. Lisensierer også samme teknologi inn i andres skreddersydde brikker. Fra møtet: Utvikler på oppdrag fra det

amerikanske forsvarsdepartementet den første strålingsherdede FPGA-en for strategiske våpensystemer, med volum ventet 2028–2030.

Nordic Semiconductor (NOD) – Ledende leverandør av Bluetooth Low Energy, teknologien som gjør at klokker, hodetelefoner, sensorer og smarthjem-produkter kan kommunisere trådløst med minimalt strømforbruk. Porteføljen inkluderer også annen kommunikasjonsteknoloogi som mobilt IoT og Wi-Fi, samt strømstyringsbrikker, og i 2026 har selskapet lansert brikker med innebygd AI for lokal prosessering. Fra møtet: Samtale med selskapets amerikanske team om strategiske kunder, edge AI, kombinasjonen av regnekraft og trådløs kommunikasjon, og minnemangel i leverandørkjeden.

Nettverk og optikk

Lumentum (LITE) – Lager lasere og optiske komponenter som gjør elektriske signaler om til lys og tilbake, en forutsetning for at tusenvis av AI-brikker skal kunne kommunisere. Fra møtet: Veksten begrenses av egen produksjonskapasitet, ikke etterspørsel. Har tidoblet EML (electro-absorption-modulated laser, moduler brukt i optiske kabler) kapasiteten på to år og fortsetter å bygge ut på tvers av fire fabrikker frem mot 2028, som de venter blir et år med et markert hopp i etterspørselen når optikk tas i bruk innenfor scale-up domenet.



Arista Networks (ANET) – Lager Ethernet-svitsjer og programvaren som styrer nettverkene i verdens største datasentre. Fra møtet: AI-omsetningen ventes mer enn doblet i år, til minst 3,5 milliarder dollar, med scale-across som ny vekstmotor. Kundene går fra Nvidias InfiniBand til åpen Ethernet. Veksten avhenger blandt annet av brikkeleveranser fra Broadcom.

Cisco (CSCO) – Verdens største nettverksselskap, med sikkerhet og samarbeidsverktøy (Webex, videoutstyr utviklet i Oslo) i tillegg. Fra møtet: AI-gjennomgang av 11 milliarder linjer kode avdekker sårbarheter som ikke kan rettes i eldre maskinvare, noe Cisco mener vil fremtvinge en utskiftningsbølge. Sterk etterspørsel fra stater etter egen infrastruktur.

Credo Technology (CRDO) – Spesialist på høyhastighetsforbindelser: aktive kobberkabler som forlenger avstanden kobber kan nå, brikker til optiske moduler og en ny type optikk som varsler før den svikter. Fra møtet: Optikkvirksomheten guides til over 600 millioner dollar i år. Pålitelighet er blitt et kjøpskriterium fordi én ustabil kobling kan stanse en hel klynge med opptil en million GPU-er.

Napatech (NAPA, Oslo Børs) – Dansk selskapsom leverer programmerbare nettverkskort (SmartNIC) basert på FPGA-brikker. Kortene settes inn i servere og avlaster oppgaver serverens egen prosessor ellers ville brukt mye kapasitet på. Kundene er leverandører av nettverksovervåking og cybersikkerhet, teleoperatører, myndigheter og finansaktører. Selskapet har lansert et 400 gigabit-kort rettet mot AI-datasentre, der d-Matrix er første kunde.

Produksjonsutstyr til halvlederfabrikkene

Lam Research (LRCX) – Lager maskinene som etser og belegger silisiumskivene i halvlederfabrikkene. Jo mer tredimensjonale brikkestrukturene blir, jo mer tid tilbringer skivene i Lams maskiner. Fra møtet: Tredje år på rad med vekst over markedet for produksjonsutstyr og rekordhøy bruttomargin. Har startet å bruke roboter for vedlikehold og reparasjon av maskiner ute hos kundene, men fortsatt tidlig fase.

Applied Materials (AMAT) – Det bredeste utstyrsselskapet i bransjen, med rundt 19 prosent av utstyrsinvesteringene i en typisk fabrikk, med utstyr for både avansert logikk og DRAM-

minne. Fra møtet: Vekstanslaget for utstyr er hevet tre ganger i år, til nær 40 prosent, og 2027 ventes å bli sterkt. Tilgang på ferdige fabrikker er det som begrenser veksten.

Minne, lagring og infrastruktur

Seagate Technology (STX) – En av to gjenværende produsenter av harddisker, som fortsatt lagrer rundt 85 prosent av dataene i datasentrene. Fra møtet: Selger nå på bestillinger med faste kontrakter ett år frem og volumavtaler flere år ut, hvor pris fastsettes ved kontraktssignering. Ny laserbasert teknologi (HAMR) gir mer kapasitet per disk og planlegger ingen kapasitetsutvidelser. Investerer kun 4–6 prosent av omsetningen, og økt kapasitet kommer derfor utelukkende fra teknologiforbedringer. Bruk av AI gjør øker behovet for lagring. Økt salg til neoclouds, men fortsatt en liten andel sammenlignet med hyperscalers.

NetApp (NTAP) – Leverer lagringssystemer til bedrifter, der verdien ligger i programvaren mer enn i selve diskene. Fra møtet: Produktsalget vokste rundt 50 prosent år-over-år i forrige kvartal, langt over historisk nivå. Antall AI-prosjekter er tredoblet på ett år, foreløpig mest datainnsamling, men inferens ventes å bli den største delen. Inngått avtale med Google for suverene skyløsninger, antakelig den største avtalen i selskapets historie. Tre prisøkninger i år på grunn av høyere komponentkostnader.

Super Micro Computer (SMCI) – Bygger servere og komplette rack for AI-datasentre, testet under full belastning i fabrikken slik at de kan settes i drift samme dag de ankommer. Fra møtet: Mål om 68,5 milliarder dollar i omsetning i regnskapsåret 2027, med 60 milliarder i ordrebok. Økende etterspørsel etter CPU-er, 10–20 prosent av ordrene er systemer med CPU-er til agent-arbeid. Jobber med å stramme inn betalingsbetingelser og arbeidskapital etter noen turbulente år.

Nutanix (NTNX) – Programvare som gjør standard servere om til en komplett skyplattform, og det viktigste alternativet til VMware etter Broadcoms oppkjøp. Fra møtet: Kjøpte egne GPU-servere for 20 millioner dollar og kjører open source-modeller for utviklerne, med ett års tilbakebetalingstid. Serverne kundene kjøper er blitt fire til fem ganger dyrere på ett år, noe som forsinker enkelte prosjekter. VMware-migreringen er en 5–10 års reise, migrasjonsprosessen er stort sett automatisert, men AI kan hjelpe kunder som har mye skreddersøm på toppen av VMware i overgangsfasen.

Selvkjørende kjøretøy og fysisk AI

Aurora Innovation (AUR) – Utvikler Aurora Driver, et selvkjørende system for lastebiler, av grundere med bakgrunn fra Waymo og Tesla. Fra møtet: Har kjørt uten sjåfør siden april 2025 og sikter mot 200 lastebiler ved årsskiftet. Prisen ligger under kostnaden for en menneskelig sjåfør, bilene kan doble sin utnyttelsesgrad og mer forutsigbar kjøring krever mindre drivstoff. Partnerskap med Volvo og PACCAR for lastebiler tilpasset systemet.



Kodiak AI (KDK) – Selvkjørende lastebiler uten behov for detaljerte forhåndskart, med samme system for motorvei, industriområder og forsvar. Fra møtet: 35 lastebiler uten sjåfør i drift døgnet rundt i Permian-bassenget i Texas, med 100 på kontrakt. Sikter mot kjøring uten sjåfør på offentlig motorvei innen utgangen av 2026. Hevder vesentlig lavere kapitalforbruk enn konkurrentene.

Intuitive Surgical (ISRG) – Ledende innen robotkirurgi med da Vinci-systemet, som ble brukt i over tre millioner inngrep i fjor. Fra møtet: Mener 17 millioner inngrep fortsatt kan flyttes over til robot. Femte generasjon har kraftsensorer i instrumentene, en forutsetning for at roboten på sikt kan utføre deloppgaver selv. Fjernkirurgi ventes sent 2027 eller tidlig 2028. Samarbeider med Nvidia om AI-modeller.



Intuitive Surgical

QuantumScape (QS) – Utvikler faststoffbatterier med litium-metall som skal gi lengre rekkevidde, raskere lading og bedre sikkerhet enn dagens litium-ion. Lisensierer teknologien i stedet for å bygge fabrikker selv. Fra møtet: Samarbeider med fire av verdens ti største bilprodusenter, med Volkswagen og Honda som de kjente. Ser også en mulighet i batterier plassert ved GPU-rack i datasentre fra rundt 2028. Vesentlige inntekter ventes først rundt 2029.

Programvare, plattformer og data

SoFi Technologies (SOFI) – Digital bank i USA som har gått fra studielån til en komplett finansiell plattform med 15 millioner medlemmer. Fra møtet: Omsetningen vokser 40 prosent og inntjening 60 prosent. Halvparten av alle nye produkter selges til eksisterende kunder. Har lansert AI-rådgiver og egen stablecoin.

Planet Labs (PL) – Utvikler og eier en flåte av små satellitter og fotograferer hele jordens landmasse hver dag. Fra møtet: Nye satellitter med 30 cm oppløsning og samarbeid med Nvidia for bruk av GPU-er om bord for å analysere bildene i bane. Selger nå også til stater (Japan, Sverige, Tyskland), som ønsker eierskap til satellittene. Forsvar og etterretning er den

sterkeste driveren. AI gjør bildearkivet siden 2017 mer verdifullt, fordi de kan tilby tjenesten på tvers av segmenter uten å bygge skreddersydde analyseverktøy per segment.



Planet Labs

3.0 Noen begreper som gjør at du og jeg skjønner litt mer av hva som skjer

Nedenfor følger beskrivelser av ord og begreper vi diskuterte mye under turen. De økte vår forståelse, kanskje den også øker din? Tungt, men sannsynligvis verdt det.

3.1 Heterogene datasentre

Tenk på et datasenter som en garasje, og på inferens som turer du skal kjøre. Problemet er ikke at du mangler biler. Problemet er at du har parkert én type bil og prøver å bruke den til alt.

Inferens er å bruke en ferdigtrent **modell**. Du stiller et spørsmål, den svarer **token** for token.

Jobben har to ulike faser:

1. Prefill = å lese hele spørsmålet på én gang. Tungt, parallelt, «motoren går for fullt».
2. Decode = å skrive svaret, ett ord om gangen. Lett for motoren, men du må hele tiden hente frem det du allerede har sagt. Det er et minne-problem, ikke et hestekrefter-problem.

GPU fill er hvor mye av bilen du faktisk bruker. En GPU kan se «opptatt ut» mens den egentlig venter på bagasjen. Da betaler du for en sportsbil som står i tomgang utenfor butikken.

- **Homogent datasenter** = garasje med bare like biler. Enkelt å eie. Dårlig match når turene er ulike.
- **Heterogent datasenter** = garasje med flere biltyper, og noen som bestemmer hvilken bil som tar hvilken etappe.
- **Én bruker vs. mange**:Én person som venter på svaret nå, vs. tusen jobber som bare skal bli ferdige billigst mulig i natt.
- **Raskeste vs. billigste tokens**:Hvor fort teksten kommer frem for deg, vs. hva det koster å produsere en million slike ord.

Garasjen

Du eier en garasje. Oppdragene ser slik ut:

Tur	**Hva det egentlig er**	**Feil bil**	**Riktig bil**
Ned til butikken	Kort, interaktivt, du venter i døra	Lastebil	Bybil
Langtur på motorvei	Lang kontekst, langt svar	Bybil som må fylles hvert 10 min	Bil m enorm tank og fart
«Jeg skal rekke flyet»	Én bruker, lav ventetid	Buss i rute	Sportsbil
Flyttelass/nattlevr.	Mange brukere, høy volum,	Sportsbil	Lastebil

pris teller

Bilene i garasjen

Lastebilen: NVIDIA-GPU-ene (xAI / Colossus-stil).

Den kan alt. Trening, prefill, decode, bilder, fine-tuning. Du har mange av dem, de er standard, reservedeler finnes overalt.Til butikken er den sløsing. Til flyttelass er den uslåelig. Når garasjen er full av like lastebiler og alle skal «bare raskt innom butikken», blir fill-en dårlig. Motoren går, men planet er halvtomt.

Cerebras

Sportsbilen med tanken innebygd i chassiset.

Du slipper å stoppe og hente drivstoff fra et eksternt lager for hvert token. Derfor kan én passasjer få teksten i 1 000–3 000 ord i sekundet.Dyr i innkjøp, tar stor plass, og du får ikke stablet seks ulike modeller i samme sete. Perfekt når du sitter og venter. Dårlig valg hvis jobben er å frakte grus hele natten.

d-Matrix

En varebil bygd for å ha varene i setet, ikke i baksetet. Corsair kan stå ved siden av lastebilen i samme garasje. Den er sterk når du skal skrive svaret fort uten å tømme GPU-ens minnebuss. Raptor (neste modell) er løftet om enda kortere vei mellom hjerne og bagasje.Ikke en erstatning for lastebilen. En spesialist for decode-etappen.

CPU / nett

Sykkelbudet. Henter verktøy, søker i arkivet, åpner en sandbox. Å bruke sportsbilen til det er bortkastet.

Gimlet

Ikke en bil. Det er **vaktsjefen** ved porten.Du sier «kjør denne agenten». Vaktsjefen splitter turen: lastebil leser prompten, sportsbil/varebil skriver svaret, sykkelbud henter verktøy. Samme garasje, flere biler, én tur. Det er heterogen inferens.

Postcards From The Future

Hetrogene datasentre vokser frem – Hva er det?

Tenk på et datasenter som en garasje, og på **inferens** som turer du skal kjøre. Problemet er ikke at du mangler biler. Problemet er at du har parkert én type bil og prøver å bruke den til alt.
Inferens er å bruke en ferdigtrent modell: du stiller et spørsmål, den svarer **token** for token.

Tur	**Hva det egentlig er**	**Feil bil**	**Riktig bil**
Ned til butikken	Kort, interaktivt, du venter i døra	Lastebil	Bybil
Langtur på motorvei	Lang kontekst, langt svar	Bybil som må fylles hvert 10 min	Bil m enorm tank og fart
«Jeg skal rekke flyet»	Én bruker, lav ventetid	Buss i rute	Sportsbil
Flyttelass/nattleveranse	Mange brukere, høy volum, pris teller	Sportsbil	Lastebil

Lastebilen: NVIDIA-GPU-ene (xAI / Colossus-stil) **Sportsbilen** med tanken innebygd i chassiset: **Cerebras**. En varebil bygd for å ha varene i setet, ikke i baksetet; **d-Matrix**	**Sykkelbudet**: **CPU / net.** Henter verktøy, søker i arkivet, åpner en sandbox. **Vaktsjefen: Gimlet** Ikke en bil. Det er **vaktsjefen** ved porten.

Postcards From The Future

Hetrogene datasentre – flere brukere og raske tolkens

	Én bruker (interaktivitet, TTFT, agenter, stemme, kode)	**Mange brukere** (aggregert tok/s, batch, nattjobber, høy occupancy)
Raskeste tokens	Cerebras (og Groq-klasse LPU). 70B på ~2 100 tok/s, 120B-klasse ~3 000 tok/s, trillion-MoE ~1 000 tok/s. Gimlet flytter decode/spec-decode hit og lar GPU ta prefill. d-Matrix Corsair som spec-decoder: 2–5× raskere end-to-end vs. GPU-only spec-decode. Grok-flaggskip taper her.	Cerebras + Gimlet-mix ved høy concurrent load, eller dedikerte decode-racks. d-Matrix rack-tall (30k tok/s på 70B) er aggregert, ikke per bruker. Homogene GPU-farmer kan nå høy sum, men hver bruker ser 50–150 tok/s. xAI vinner på kapasitet, ikke på tokens per sekund per session.
Billigste tokens	Groq / åpne små modeller ($0.05–0.15/M inn på 8B–20B). Cerebras er sjelden billigst per token — du betaler for hastighet. xAI Fast ($0.20/$0.50) er «billig nok» hvis du må ha Grok-kvalitet. d-Matrix TCO-løfte er sterkere når du eier racket enn som delt API.	Homogen GPU-fyll + d-Matrix TCO. Når batchen er stor, vinner H100/B200/B300 på $/token fordi silisiumet er massemarked og allerede avskrevet i treningsklynger (Colossus-logikken). d-Matrix hevder 3–13× tokens per dollar vs. A100/H100 på 13B-klassen i egne whitepapers — det er vendor-tall.

- Raskest til én: Du tar sportsbilen (Cerebras/Groq-klasse) på decode. Du betaler for at du ikke skal vente.
- Billigst til mange: Du fyller lastebilene (GPU-haller som Colossus) og kjører natt. Prisen per kilo faller når planet er fullt.
- Raskest til mange: Enten mange sportsbiler (dyrt), eller vaktsjefen som gir hver etappe riktig bil så summen av turer går fort uten at alle sitter i samme kø.
- Billigst til én: En liten, billig bybil (små åpne modeller på Groq-klasse / Grok Fast). Ikke flaggskip-Grok i sportsbil-modus.

Den vanlige feilen er å kjøpe bare lastebiler fordi de vant forrige runde (trening), og så klage over at turen til butikken tar fire minutter og koster som et flyttelass. GPU fill er akkurat det: lastebilen er «i bruk», men den gjør en jobb den ikke er formet for.

Kort sagt: homogen garasje er enkel. Heterogen garasje er tregere å eie, men hver tur koster mindre tid eller penger, hvis vaktsjefen vet hvilken bil som skal ut.

3.2 Scale up, scale out & across

Begrepene brukes i flere fagfelt, men kjernen er den samme. Hvordan du øker kapasitet. Forskjellen ligger i hva du gjør større – én enhet, flere like enheter, eller flere steder og kontekster. Dette er blitt datasentrenes nye stammespråk. Ingen er helt enig om definisjonene, men under er vår forståelse. De neste kvartallstallene blir vanskelig uten å skjønne forskjellen mellom disse. Tror vi da.

Kort oversikt

Begrep	**Kjerneidé**	**Typisk spørsmål**
Scale up	Gjør den samme enheten sterkere	Kan vi gi denne maskinen, teamet eller metoden mer kraft?
Scale out	Legg til flere like enheter	Kan vi fordele last på flere noder, team eller steder?

Scale across	Knytt sammen ulike steder, systemer eller kontekster	Kan flere datasentre, markeder eller organisasjoner fungere som ett system?

De tre er ikke gjensidig utelukkende. I moderne AI-infrastruktur brukes de ofte samtidig.

Scale up – vertikal skalering

Scale up betyr å øke kapasiteten inne i én eksisterende enhet. I IT kalles dette vertikal skalering. Mer CPU, RAM, GPU, minnebåndbredde eller raskere intern kommunikasjon i samme server.

IBM beskriver det slik: *scale-up gjøres «by adding more resources to an existing system to reach a desired state of performance».*

I AI-datasentre er scale-up ofte det å pakke flere GPU-er i samme node eller rack og knytte dem tett sammen (NVLink, NVSwitch og liknende), slik at de opptrer som én stor datamaskin med felles minne og svært lav latenstid.

Styrker: Enkelt å forstå. Godt for arbeidsbelastninger som trenger delt minne og tight koordinering. Lav intern latenstid.

Begrensninger: Fysisk tak. Kabinett, strøm, kjøling og bussbredde. Én stor node blir et enkeltfeilpunkt. Kostnaden per ytelsesøkning stiger ofte bratt.

Du oppgraderer veidekket slik at samme vei tåler mer trafikk – i stedet for å legge flere filer.

Scale out – horisontal skalering

Scale out betyr å øke kapasiteten ved å legge til flere noder og fordele arbeidet mellom dem. IBM knytter dette til distribuerte arkitekturer og «pay-as-you-grow».

I praksis: flere servere bak en lastbalanserer, flere pods i Kubernetes, flere shards i en database, flere GPU-noder i et treningskluster. Hver node er en selvstendig regneenhet; nettverket binder dem til et ressursbasseng.

Styrker: Nærmest ubegrenset vekst i teorien. Bedre feiltoleranse (én node kan falle ut). Ofte billigere commodity-maskinvare. Passer stateless tjenester, mikroservices og dataparallell trening.

Noen begrensninger kan være at det krever deling av arbeidsmengde. Mer kompleksitet som orkestrering, konsistens, nettverk, observabilitet. Kommunikasjon mellom noder koster latenstid og båndbredde. Når kommunikasjon tar mer tid enn beregning, slutter systemet å skalere lineært («communication bound»).

Det vil si, du legger flere filer, slik at flere biler kan kjøre parallelt.

Hyperscalere (Google, Amazon, Microsoft) er i stor grad bygget på scale-out: mange relativt like maskiner, ikke én supermaskin. Britannica oppsummerer skillet slik: tradisjonelle datasentre *«scale up» ved å oppgradere eksisterende maskinvare; hyperscalere «scale out» ved å legge til flere datamaskiner.*

Scale across – på tvers av steder og systemer

Scale across er det nyeste og minst standardiserte begrepet. I AI- og nettverksindustrien fra ca. 2025–2026 har det fått en ganske presis betydning:

Scale-out holder seg vanligvis innen ett datasenter. Scale-across knytter sammen ressurser i ulike geografiske lokasjoner – campus, metro, region eller sky – via DCI, optisk transport eller WAN, slik at flere klynger kan opptre som ett logisk system.

Drivenets formulerer det kort:

«Extending high-performance networking across multiple data centers to support workloads too large for a single site»

Ciena beskriver poenget som evnen til å trene én AI-modell på GPU-er som fysisk står i ulike campus eller regioner – «one logical AI training environment, even when the infrastructure is physically distributed».

NVIDIA kaller scale-across «*a new dimension, orthogonal to the existing connectivity options of scale-up and scale-out».*

Hvorfor begrepet oppsto nå? Ett datasenter treffer tak på strøm, tomt og kjøling. De største modellene krever mer energi enn ett anlegg kan levere. Da må klynger spennes over flere bygg.

Prisen: Høyere latenstid, mer jitter, lavere effektiv båndbredde, dyrere optikk. Synkron trening over lange avstander er krevende; derfor brukes scale-across oftere til oppgavefordeling, redundans, inferens og «nær-synkron» trening enn til tett GPU-til-GPU-kommunikasjon.

Et sitat som viser at definisjonen fortsatt er i bevegelse:

«Scale-up is highly localized. It's synchronous, message passing type, low latency… Scale-out is basically within the pod. … Scale-across can vary [depending] on who you talk to. It can be 10 kilometers to thousands of kilometers.»

Hvordan de henger sammen

I moderne AI-fabrikker er de tre lag, ikke alternativer:

1. Scale up gjør hver node så rask som mulig (intra-node / intra-rack).

2. Scale out binder nodene til en klynge i ett datasenter.

3. Scale across binder klyngene til et større, geografisk fordelt system.

En typisk sammenlikning:

Dimensjon	**Scale up**	**Scale out**	**Scale across**
Omfang	Én node / ett rack	Mange servere i ett DC	Flere DC / regioner
Mål	Maks ytelse per enhet	Stor klynge	Global / multi-site kap
Avstand	Under ~10 m	10 m–2 km	Ti- til tusenvis av km
Nett	NVLink, NVSwitch, CXL	InfiniBand, RoCEv2, Ethernet	DCI, koh, optikk, WAN
Latenstid	Lavest	Middels	Høyest

Skalerbarhet	Begre.av kabinett/el	Høy inne i DC	Høy i rekkevidde, dyr

Kilder for tabellen: Optcore, Asteraix, HYTOPTODEVICE.

Praktisk tommelfingerregel er at trenger du mer kraft i én sammenhengende beregning (delt minne, lav latenstid)? → Scale up.

Trenger du mer total kapasitet og robusthet, og arbeidet kan deles? → Scale out.

Har én lokasjon, ett system eller én kontekst fysisk, politisk eller organisatorisk tak? → Scale across.

De fleste systemer som virkelig blir store, bruker alle tre: først mer muskel i hver enhet, så flere enheter, så flere steder som opptrer som ett.

3.3 Lys, speil & optikk

Lumentum og Coherent selger ikke «AI-chips». De selger lyskilder og optiske byggeklosser som gjør at GPU-er, TPU-er og svitsjer kan snakke sammen når kobberkabler blir for trege, for varme og for korte. Det er derfor etterspørselen er så sterk, og derfor 2028 ofte kalles et vendepunkt. Vi kaller det «Det Optiske Big Bang skjer i 2028».

Enkel idé først

Tenk på et AI-cluster som en by.

- Kobber er gatene inne i ett kvartal. Fungerer bra på korte avstander.
- Optikk er motorveiene. Lys bærer mer data, lenger, med mindre tap.
- Når klyngene blir større og hastigheten går fra 800G til 1.6T og 3.2T, må motorveien trekkes inn i selve kvartalet – først mellom rack, så inne i racken, til slutt tett på selve brikken.

Lumentum og Coherent lager «lyspærene», modulatorene, modulene og i økende grad hele optiske systemer som gjør den flyttingen mulig.

Begreper & Stammespråk

Postcards From The Future

Ordliste for stammespråket for optisk lys

InP (indiumfosfid)
Halvledermaterialet de fleste høyhastighetslasere er laget av. Vanskelig å produsere, liten wafer, lang kvalifisering. Derfor er InP-kapasitet den reelle flaskehalsen.

EML (electro-absorption modulated laser)
En laser som både lager lyset og koder dataene på samme brikke. Arbeidshesten i mange 800G- og 1.6T-moduler. Lumentum har særlig sterk posisjon her.

CW-laser (continuous wave)
En laser som bare lager et stabilt, kontinuerlig lys. Selve datakodingen skjer i en annen komponent, ofte silisiumfotonikk. Trengs i SiPh-moduler og i CPO/NPO.

UHP-laser (ultra-high-power)
Ekstra kraftig CW-laser. Én laser kan mate mange kanaler. Nøkkelen i eksterne lyskilder til CPO/NPO.

ELS (external laser source)
Laseren står utenfor den varme svitsj-/XPU-pakken og sender lys inn via fiber. Mer servicevennlig enn å lime laseren fast på selve ASIC-en.

Pluggbar modul
Dagens standard: en boks du plugger i fronten av svitsjen (800G, 1.6T, senere 3.2T).

NPO (near-packaged optics)
Optikken sitter rett ved siden av brikken på kortet. Enklere enn CPO, raskere å innføre, ofte brukt som bro mot full CPO.

CPO (co-packaged optics)
Optikken sitter i samme pakke som svitsj- eller XPU-brikken. Kortere elektrisk vei, lavere effekt og lavere latens – men vanskeligere å lage, teste og bytte.

OCS (optical circuit switch)
En optisk «krysskobling» som sender lys videre uten å gjøre det om til elektrisitet først. Brukes til å omkonfigurere AI-nettverk, spare strøm og rute rundt dårlige noder.

Postcards From The Future

Fire måter å skalere AI på, med ulik optisk intensitet

Begrep	Hva det betyr	Avstand	Optikkbehov
Scale-across	Mellom datasentre/campus	Lang	Pumpelasere, DCI, ZR+
Scale-out	Mellom rack i samme hall	Middels	800G/1.6T-pluggbarer, etter hvert CPO-svitsjer
Scale-up	Inne i klyngen/mellom GPU-er	Kort	Kobber i dag, NPO/CPO fra 2027–2028
Scale-in	Inne i selve pakken	Svært kort	Fremtidig optikk tett på XPU

Lumentums *Wupen Yuen* oppsummerte **båndbredden** slik:
scale-across = 1, scale-out = 10, scale-up = 100, scale-in = 1 000.

Hvorfor 2028 kalles et «big bang»

Det er ikke ett produkt som eksploderer. Det er flere kurver som møtes. De konvergerer:

1. Neste generasjon XPU og raskere SerDes kommer. CPO/NPO festes til nye plattformer, ikke gårsdagens GPU-er.

2. Optical scale-up starter sent 2027 og skal vokse i 2028. NPO kan komme et kvartal før CPO.
3. 3.2T-moduler går fra tidlig volum i 2027 til stor andel i 2028. Goldman har blant annet løftet hele det globale modulmarkedet kraftig mot 2028.
4. Kobbergrensen flyttes innover i racket. Første scale-up-optikk går også på tvers av flere rack, ikke bare inne i ett.
5. Ny laser-kapasitet kommer sent: Coherent dobler InP igjen i 2027; Lumentums Greensboro-fab ventes å gi inntekt tidlig 2028. Etterspørselen er der før full kvalifisert kapasitet.

Lumentum, om selve vendepunktet, eller Big Bang

«Lumentum expects NPO deployments to begin around late 2027 and identifies 2028 as a key industry inflection point for optical Scale Up.»

CEO Michael Hurlston, om etterspørsel og bookinger:

«The capex numbers from the US hyperscalers are enormous and there seems to be no end in sight. We're falling further and further behind the demand. We would be sold out through all of 2028 within two quarters.»

Hurlston, om hvorfor arkitekturen skifter:

«Lumentum is positioned at the heart of a secular industry shift. As AI compute workloads increase in both speed and bandwidth, data center architects are turning to optical links as a primary means of connectivity.»

Lumentum om timing for scale-up-lasere:

«We remain confident that demand for ultrahigh-power laser chips will begin ramping in the second half of 2027 in preparation for customers' scale-up deployments in 2028.»

Wupen Yuen om hvor stort det kan bli etter hvert som optikk går dypere inn:

«Scale across is one, scale out is 10 in bandwidth, scale up is 100, scale in is 1,000 … as intensity of optical demand increases, and with XPU numbers going up, I would say Lumentum's best days are yet to come.»

Coherent-CEO Jim Anderson om synlighet:

«Customer demand remains exceptionally strong with no signs of attenuation, and our visibility continues to extend further into the future with orders now reaching into calendar 2028 and customer LTAs extending to the end of the decade.»

Anderson om CPO som marked:

«CPO is … a transformational growth opportunity for the company. We see that market size as over $15 billion, and that's probably a conservative estimate over the coming years. … scale-up CPO revenue in the second half of calendar '27.»

Anderson om selve tesen:

«AI scales on optical connectivity.»

Slik henger det sammen i én setning. Tror vi da.

2026–27 er boom i pluggbare 800G/1.6T og i laserbrikkene inni dem.2028 er året da optikk forventes å ta et hopp inn i AI-klyngen (NPO/CPO scale-up), samtidig som 3.2T og OCS skalerer – mens InP-lasere fortsatt er knappe.

Derfor er det ikke «enda en transceiver-syklus». Det er et skifte fra kobber + pluggbar boks til lys som infrastruktur inne i maskinen. Lumentum og Coherent sitter på lyskilden den overgangen krever.

4.0 Avslutning

Vi er heldige som får reise rundt i silikon dalen i den perioden som vi tror vil bli kalt den mest crazy perioden på kloden så langt i dette årtusenet. Tusen takk til DNB Carnegie, Christoffer og Mona Cathrin, som arrangerte nok en herlig tur.

En tur til Silicon Valley gir ikke fasit. Den gir kalibrering.

Vi kom ikke hjem med tjue investeringsanbefalinger og et ferdig kart. Vi kom hjem med et skarpere skille mellom det som er blitt konsensus, det som fortsatt er undervurdert, og det som bare er støy kledd i godt språk. De store linjene er det vi tar med inn i arbeidet videre: hvordan vi leser selskaper, hvilke spørsmål vi stiller, og hvor vi mener risiko og avkastning faktisk sitter de neste årene.

Andelshavernes og investorenes kapital skal ikke jakte den mest imponerende pitchen. Den skal eie eksponering mot krefter som er dype nok til å bære flere selskaper - og være disiplinert nok til å si nei når historien er sterk, men forutsetningene tynne. Det er den standarden vi tar med oss tilbake fra Silicon Valley.

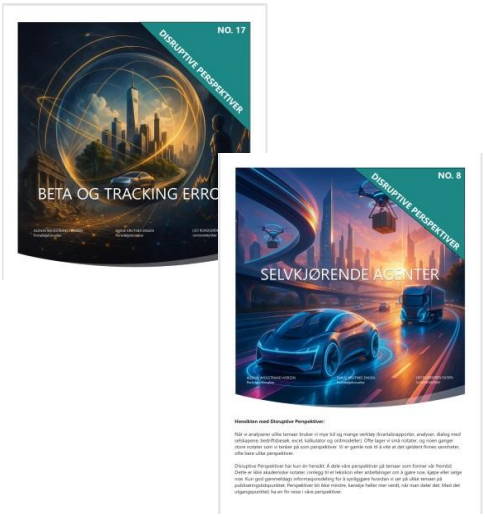
Takk for tilliten. Vi fortsetter arbeidet.

Vi sees i fremtiden.



Reisebrevet er skrevet på bakgrunn av møter i Silicon Valley 7.–11. september 2026 og gjengir selskapenes egne uttalelser og våre inntrykk. Det er ikke ment som investeringsråd.

Mer gratis info?



Postkortfrafremtiden.no



Følg med gjennom LinkedIn, Substack og X

- Følg med på X, Substack og LinkedIn
- Skriver ofte om disrupsjoner og aksjemarkedet

....samt podkasten *Utbytte*

